



深蓝学院  
shenlanxueyuon.com

## 第十二章作业提示

主讲人 会打篮球的猫





# 第一题

1 样例代码给出了使用 LM 算法来估计曲线  $y = \exp(ax^2 + bx + c)$  参数  $a, b, c$  的完整过程。

① 请绘制样例代码中 LM 阻尼因子  $\mu$  随着迭代变化的曲线图

```
Test CurveFitting start...
iter: 0 , chi= 36048.3 , Lambda= 0.001
iter: 1 , chi= 30015.5 , Lambda= 699.051
iter: 2 , chi= 13421.2 , Lambda= 1864.14
iter: 3 , chi= 7273.96 , Lambda= 1242.76
iter: 4 , chi= 269.255 , Lambda= 414.252
iter: 5 , chi= 105.473 , Lambda= 138.084
iter: 6 , chi= 100.845 , Lambda= 46.028
iter: 7 , chi= 95.9439 , Lambda= 15.3427
iter: 8 , chi= 92.3017 , Lambda= 5.11423
iter: 9 , chi= 91.442 , Lambda= 1.70474
iter: 10 , chi= 91.3963 , Lambda= 0.568247
iter: 11 , chi= 91.3959 , Lambda= 0.378832
problem solve cost: 0.581061 ms
makeHessian cost: 0.349348 ms
LM results have been saved at: /home/lcx/lm_results.txt
-----After optimization, we got these parameters :
0.941939 2.09453 0.965586
-----ground truth:
1.0, 2.0, 1.0
```



# 第一题

② 将曲线函数改成  $y = ax^2 + bx + c$ ，请修改样例代码中残差计算，雅克比计算等函数，完成曲线参数估计。

- 生成数据
- 残差
- 雅克比

```
70 // 构造 N 次观测
71 for (int i = 0; i < N; ++i) {
72
73     double x = i/1000.;
74     double n = noise(generator);
75     // 观测 y
76     // double y = std::exp( a*x*x + b*x + c ) + n;
77     double y = a*x*x + b*x + c + n;
78 }
```

```
27 // 计算曲线模型误差
28 virtual void ComputeResidual() override
29 {
30     Vec3 abc = vertices_[0]->Parameters(); // 估计的参数
31     // residual_(0) = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) ) - y_; // 构建残差
32     residual_(0) = abc(0)*x_*x_ + abc(1)*x_ + abc(2) - y_; // 构建残差
33 }
34
35 // 计算残差对变量的雅克比
36 virtual void ComputeJacobians() override
37 {
38     // Vec3 abc = vertices_[0]->Parameters();
39     // double exp_y = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) );
40
41     Eigen::Matrix<double, 1, 3> jaco_abc; // 误差为1维，状态量 3 个，所以是 1x3 的雅克比矩阵
42     // jaco_abc << x_ * x_ * exp_y, x_ * exp_y, 1 * exp_y;
43     jaco_abc << x_ * x_, x_, 1;
44     jacobians_[0] = jaco_abc;
45 }
```

# 第一题

- ② 将曲线函数改成  $y = ax^2 + bx + c$ ，请修改样例代码中残差计算，(观测数量的讨论)  
雅克比计算等函数，完成曲线参数估计。

```
lcx@lcx:~/Desktop/vio_homework/ch3/CurveFitting_LM/build$ ./a.out
Test CurveFitting start...
iter: 0 , chi= 719.475 , Lambda= 0.001
iter: 1 , chi= 91.395 , Lambda= 0.000333333
problem solve cost: 0.097857 ms
makeHessian cost: 0.055884 ms
LM results have been saved at: /home/lcx/lm_results.txt
-----After optimization, we got these parameters :
1.61039 1.61853 0.995178
-----ground truth:
1.0, 2.0, 1.0
```

可以看出，最终的优化结果为 (1.61039 1.61853 0.995178)，与真值 (1.0 2.0 1.0) 相比，误差比较大，优化结果并不好。

因此，考虑提高观测数据的数量，由原先的 100 个数据提高到 1000 个，且依旧保证  $x$  在 (0~1) 范围内均分。

```
lcx@lcx:~/Desktop/vio_homework/ch3/CurveFitting_LM/build$ ./a.out
Test CurveFitting start...
iter: 0 , chi= 7114.25 , Lambda= 0.01
iter: 1 , chi= 973.88 , Lambda= 0.00333333
iter: 2 , chi= 973.88 , Lambda= 0.00222222
problem solve cost: 2.77373 ms
makeHessian cost: 2.17039 ms
LM results have been saved at: /home/lcx/lm_results.txt
-----After optimization, we got these parameters :
0.958923 2.06283 0.968821
-----ground truth:
1.0, 2.0, 1.0
```

此时，可以看出使用 1000 个数据后，估计的结果为 (0.958923 2.06283 0.968821)，与真值相比已经非常接近了，估计结果较准。

为了做进一步验证，将数据增加至 2000 个，结果如下图所示：

```
lcx@lcx:~/Desktop/vio_homework/ch3/CurveFitting_LM/build$ ./a.out
Test CurveFitting start...
iter: 0 , chi= 14374.2 , Lambda= 0.02
iter: 1 , chi= 1979.22 , Lambda= 0.00666667
iter: 2 , chi= 1979.22 , Lambda= 0.00444444
problem solve cost: 1.78892 ms
makeHessian cost: 1.46041 ms
LM results have been saved at: /home/lcx/lm_results.txt
-----After optimization, we got these parameters :
1.07765 1.97101 0.983445
-----ground truth:
1.0, 2.0, 1.0
```

此时，发现结果变化已经微乎其微，  
即增加更多的观测对估计结果的精度已经不能再有显著提升。

# 第一题

- ② 将曲线函数改成  $y = ax^2 + bx + c$ ，请修改样例代码中残差计算，雅克比计算等函数，完成曲线参数估计。（初值的讨论）

再次回到 1000 个点，这次考虑将初值(0.0 0.0 0.0)修改为(0.9 2.1 0.9)，即给待估计参数一个较好的初值，再次运行结果如下：

```
lcx@lcx:~/Desktop/vio_homework/ch3/CurveFitting_LM/build$ ./app/testCurveFitting

Test CurveFitting start...
iter: 0 , chi= 978.82 , Lambda= 0.01
iter: 1 , chi= 973.88 , Lambda= 0.00333333
problem solve cost: 0.641336 ms
makeHessian cost: 0.500614 ms
LM results have been saved at: /home/lcx/lm_results.txt
-----After optimization, we got these parameters :
0.958728 2.06304 0.968784
-----ground truth:
1.0, 2.0, 1.0
```

与上上个 1000 个点的结果图对比，发现参数估计结果在精度上并没有太大变化，推测原因是：由于我们拟合的曲线函数较简单，且只有一个极小值点，因此初值的选择并不会使得优化至错误的极小值，所以最终的精度更多地取决于观测数据的噪声。但是，较好地初值带来的好处便是，迭代次数的减少、耗时的减少，能够更快地收敛。

当然了，在后续面对真正复杂的函数时，提供较好的初值还是很有必要的。



# 第一题

- ③ 实现其他更优秀的阻尼因子策略，并给出实验对比（选做，评优秀），策略可参考论文<sup>a</sup> 4.1.1 节。

1.  $\lambda_0 = \lambda_o$ ;  $\lambda_o$  is user-specified [5].  
use eq'n (13) for  $\mathbf{h}_{lm}$  and eq'n (16) for  $\rho$   
if  $\rho_i(\mathbf{h}) > \epsilon_4$ :  $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$ ;  $\lambda_{i+1} = \max[\lambda_i/L_{\downarrow}, 10^{-7}]$ ;  
otherwise:  $\lambda_{i+1} = \min[\lambda_i L_{\uparrow}, 10^7]$ ;
2.  $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$ ;  $\lambda_o$  is user-specified.  
use eq'n (12) for  $\mathbf{h}_{lm}$  and eq'n (15) for  $\rho$   
 $\alpha = \left( \left( \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right) / \left( (\chi^2(\mathbf{p} + \mathbf{h}) - \chi^2(\mathbf{p})) / 2 + 2 \left( \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right)$ ;  
if  $\rho_i(\alpha \mathbf{h}) > \epsilon_4$ :  $\mathbf{p} \leftarrow \mathbf{p} + \alpha \mathbf{h}$ ;  $\lambda_{i+1} = \max[\lambda_i / (1 + \alpha), 10^{-7}]$ ;  
otherwise:  $\lambda_{i+1} = \lambda_i + |\chi^2(\mathbf{p} + \alpha \mathbf{h}) - \chi^2(\mathbf{p})| / (2\alpha)$ ;
3.  $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$ ;  $\lambda_o$  is user-specified [6].  
use eq'n (12) for  $\mathbf{h}_{lm}$  and eq'n (15) for  $\rho$   
if  $\rho_i(\mathbf{h}) > \epsilon_4$ :  $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$ ;  $\lambda_{i+1} = \lambda_i \max[1/3, 1 - (2\rho_i - 1)^3]$ ;  $\nu_i = 2$ ;  
otherwise:  $\lambda_{i+1} = \lambda_i \nu_i$ ;  $\nu_{i+1} = 2\nu_i$ ;

Nielsen策略（作业源码中实现的）

# 第一题

- ③ 实现其他更优秀的阻尼因子策略，并给出实验对比（选做，评优秀），策略可参考论文<sup>a</sup> 4.1.1 节。

$$[\mathbf{J}^T \mathbf{W} \mathbf{J} + \lambda \mathbf{I}] \mathbf{h}_{lm} = \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}), \quad (12)$$

$$[\mathbf{J}^T \mathbf{W} \mathbf{J} + \lambda \text{diag}(\mathbf{J}^T \mathbf{W} \mathbf{J})] \mathbf{h}_{lm} = \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}).$$

$$\rho_i(\mathbf{h}_{lm}) = \frac{\chi^2(\mathbf{p}) - \chi^2(\mathbf{p} + \mathbf{h}_{lm})}{(\mathbf{y} - \hat{\mathbf{y}})^T (\mathbf{y} - \hat{\mathbf{y}}) - (\mathbf{y} - \hat{\mathbf{y}} - \mathbf{J} \mathbf{h}_{lm})^T (\mathbf{y} - \hat{\mathbf{y}} - \mathbf{J} \mathbf{h}_{lm})}$$

$$= \frac{\chi^2(\mathbf{p}) - \chi^2(\mathbf{p} + \mathbf{h}_{lm})}{\mathbf{h}_{lm}^T (\lambda_i \mathbf{h}_{lm} + \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})))}$$

$$= \frac{\chi^2(\mathbf{p}) - \chi^2(\mathbf{p} + \mathbf{h}_{lm})}{\mathbf{h}_{lm}^T (\lambda_i \text{diag}(\mathbf{J}^T \mathbf{W} \mathbf{J}) \mathbf{h}_{lm} + \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})))}$$

(12) → 方法2、3

(13) → 方法1

(14) if using eq'n (12) for  $\mathbf{h}_{lm}$  (15)

if using eq'n (13) for  $\mathbf{h}_{lm}$  (16)

方法1

# 第一题

- ③ 实现其他更优秀的阻尼因子策略，并给出实验对比（选做，评优秀），策略可参考论文<sup>a</sup> 4.1.1 节。

通过对比，主要的修改主要在 `AddLambdatoHessianLM()`、`RemoveLambdatoHessianLM()` 和 `IsGoodStepInLM()` 三个函数中。此外还有  初值的设定：`ComputeLambdaInitLM()`

```
287 void Problem::AddLambdatoHessianLM() {
288     ulong size = Hessian_.cols();
289     assert(Hessian_.rows() == Hessian_.cols() && "Hessian is not square");
290     for (ulong i = 0; i < size; ++i) {
291         // Hessian_(i, i) += currentLambda_;
292         Hessian_(i, i) *= (currentLambda_ + 1.0);
293     }
294 }
295
296 void Problem::RemoveLambdaHessianLM() {
297     ulong size = Hessian_.cols();
298     assert(Hessian_.rows() == Hessian_.cols() && "Hessian is not square");
299     // TODO: 这里不应该减去一个，数值的反复加减小容易造成数值精度出问题？而应该保存叠加Lambda前的值，在这里直接赋值
300     for (ulong i = 0; i < size; ++i) {
301         // Hessian_(i, i) -= currentLambda_;
302         Hessian_(i, i) /= (currentLambda_ + 1.0);
303     }
304 }
```



# 第一题

- ③ 实现其他更优秀的阻尼因子策略，并给出实验对比（选做，评优秀），策略可参考论文<sup>a</sup> 4.1.1 节。

```
306 bool Problem::IsGoodStepInLM() {
307     size_t size = Hessian_.rows();
308     Eigen::MatrixXd diagH(size, size);
309     diagH.setZero();
310     for (size_t i = 0; i < size; ++i) {
311         diagH(i, i) += Hessian_(i, i);
312     }
313
314     double scale = 0;
315     scale = delta_x_.transpose() * (currentLambda_ * diagH * delta_x_ + b_);
316     scale += 1e-3; // make sure it's non-zero :)
```


```
326 double rho = (currentChi_ - tempChi) / scale;
327 double upl = 11.0;
328 double downL = 9.0;
329
330 if (rho > 0 && isfinite(tempChi)) // Last step was good, 误差在下降
331 {
332     // double alpha = 1. - pow((2 * rho - 1), 3);
333     // alpha = std::min(alpha, 2. / 3.);
334     // double scaleFactor = (std::max)(1. / 3., alpha);
335     // currentLambda_ *= scaleFactor;
336     // ni_ = 2;
337     currentLambda_ = std::max(currentLambda_ / downL, 1e-7);
338     currentChi_ = tempChi;
339     return true;
340 } else {
341     // currentLambda_ *= ni_;
342     // ni_ *= 2;
343     currentLambda_ = std::min(currentLambda_ * upl, 1e7);
344     return false;
345 }
```

# 第一题

- ③ 实现其他更优秀的阻尼因子策略，并给出实验对比（选做，评优秀），策略可参考论文<sup>a</sup> 4.1.1 节。

为了与Nielsen策略（第一问结果）进行有效对比，数据量不变，初值不变，函数依旧用exp的原函数。

```
lcx@lcx:~/Desktop/vio_homework/ch3/1_3_CurveFitting_LM/build$ ./app/testCurveFitting
Test CurveFitting start...
iter: 0 , chi= 36048.3 , Lambda= 0.001
iter: 1 , chi= 34760.2 , Lambda= 17.8946
iter: 2 , chi= 8020.58 , Lambda= 1.98828
iter: 3 , chi= 779.997 , Lambda= 0.22092
iter: 4 , chi= 348.805 , Lambda= 0.0245467
iter: 5 , chi= 145.33 , Lambda= 0.00272741
iter: 6 , chi= 101 , Lambda= 0.000303046
iter: 7 , chi= 92.3181 , Lambda= 3.36718e-05
iter: 8 , chi= 91.3999 , Lambda= 3.74131e-06
iter: 9 , chi= 91.3959 , Lambda= 4.15701e-07
problem solve cost: 0.44031 ms
makeHessian cost: 0.276777 ms
LM results have been saved at: /home/lcx/lm_results.txt
-----After optimization, we got these parameters :
0.941955  2.0945  0.9656
-----ground truth:
1.0, 2.0, 1.0
```



两种策略最终估计的参数结果近似，且都接近真值。  
但方法一迭代次数更少，耗时更短。

## 第二题

1、推导 f15。

$$\mathbf{f}_{15} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta \mathbf{b}_k^g}$$

$$\boldsymbol{\omega} = \frac{1}{2} (\boldsymbol{\omega}^{b_k} + \boldsymbol{\omega}^{b_{k+1}}) - \mathbf{b}_k^g$$

$$\alpha_{b_j b_{k+1}} = \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2$$

$$a = \frac{1}{2} (R_{b_i b_k} (a^{b_k} - b_k^a) + R_{b_i b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) (a^{b_{k+1}} - b_k^a))$$

$\alpha_{b_j b_{k+1}}$  中只有  $a$  的  $\boldsymbol{\omega}$  与  $b_k^g$  有关，所以  $\alpha_{b_j b_{k+1}}$  关于  $b_k^g$  的偏导仅对相关项求导

问题：怎么加  $\mathbf{b}_g$  扰动？？  $\mathbf{b}_g$  扰动加在哪里？？

# 第二题

1、推导 f15。

错误示范!!!

$$f_{15} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta \mathbf{b}_k^g} = \frac{\partial \frac{1}{4} \mathbf{q}_{b_i b_k} \otimes \left[ \frac{1}{2} \boldsymbol{\omega} \delta t \right] \otimes \left[ -\frac{1}{2} \delta \mathbf{b}_k^g \delta t \right] (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g}$$

正确位置:

$$f_{15} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta \mathbf{b}_k^g} = \frac{\partial \frac{1}{4} \mathbf{q}_{b_i b_k} \otimes \left[ \frac{1}{2} (\boldsymbol{\omega} - \delta \mathbf{b}_k^g) \delta t \right] (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g}$$

- 对谁加扰动，扰动项就直接跟在该变量后面
- 只有旋转变量加扰动才是乘一个微小旋转，其他均是加号！

$$\boldsymbol{\omega} = \frac{1}{2} (\boldsymbol{\omega}^{b_k} + \boldsymbol{\omega}^{b_{k+1}}) - \mathbf{b}_k^g$$

←  $-\delta \mathbf{b}_k^g$

$$\begin{bmatrix} 1 \\ \mathbf{a} + \mathbf{b} \end{bmatrix} \neq \begin{bmatrix} 1 \\ \mathbf{a} \end{bmatrix} \otimes \begin{bmatrix} 1 \\ \mathbf{b} \end{bmatrix}$$

## 第二题

### 1、推导 f15。

$$\begin{aligned} f_{15} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta \mathbf{b}_k^g} = \frac{\partial \frac{1}{4} \mathbf{q}_{b_i b_k} \otimes \left[ \frac{1}{2} (\boldsymbol{\omega} - \delta \mathbf{b}_k^g) \delta t \right] (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\ &= \frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_k} \exp([\boldsymbol{\omega} - \delta \mathbf{b}_k^g) \delta t]_{\times} (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\ &\approx \frac{1}{4} \frac{\partial \mathbf{R}_{b_i b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) \exp([-J_r(\boldsymbol{\omega} \delta t) \delta \mathbf{b}_k^g \delta t]_{\times}) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\ &= \frac{1}{4} \frac{\partial -\mathbf{R}_{b_i b_{k+1}} \left( [(\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2]_{\times} \right) (-J_r(\boldsymbol{\omega} \delta t) \delta \mathbf{b}_k^g \delta t)}{\partial \delta \mathbf{b}_k^g} \\ &= -\frac{1}{4} \left( \mathbf{R}_{b_i b_{k+1}} [(\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a)]_{\times} \delta t^2 \right) (-J_r(\boldsymbol{\omega} \delta t) \delta t) \\ &\approx -\frac{1}{4} \left( \mathbf{R}_{b_i b_{k+1}} [(\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a)]_{\times} \delta t^2 \right) (-\delta t) \end{aligned}$$

$$\begin{aligned} f_{15} &= \frac{\partial \alpha_{b_{k+1}}}{\partial \delta \mathbf{b}_k^g} \\ &= \frac{\partial \frac{1}{4} (R_{b_i b_k} \exp([\boldsymbol{\omega} - \delta \mathbf{b}_k^g) \delta t]_{\times}) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\ &= \frac{\partial \frac{1}{4} (R_{b_i b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) \exp([-J_r(\boldsymbol{\omega} \delta t) \delta \mathbf{b}_k^g \delta t]_{\times}) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\ &= \frac{\partial \frac{1}{4} (R_{b_i b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) (I + [-J_r(\boldsymbol{\omega} \delta t) \delta \mathbf{b}_k^g \delta t]_{\times}) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\ &= \frac{-\partial \frac{1}{4} (R_{b_i b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) [\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a]_{\times} (-J_r(\boldsymbol{\omega} \delta t) \delta \mathbf{b}_k^g \delta t) \delta t^2}{\partial \delta \mathbf{b}_k^g} \end{aligned}$$

当 $\boldsymbol{\omega} \delta t$ 极小时,  $J_r(\boldsymbol{\omega} \delta t) = I$ , 所以有

$$\begin{aligned} f_{15} &= \frac{\partial \alpha_{b_{k+1}}}{\partial \delta \mathbf{b}_k^g} \\ &= \frac{-\partial \frac{1}{4} (R_{b_i b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) [\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a]_{\times} (-J_r(\boldsymbol{\omega} \delta t) \delta \mathbf{b}_k^g \delta t) \delta t^2}{\partial \delta \mathbf{b}_k^g} \\ &= -\frac{1}{4} R_{b_i b_{k+1}} [\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a]_{\times} \delta t^2 (-\delta t) \end{aligned}$$



# 第二题

## 1、推导 $g_{12}$ 。

$$\begin{aligned}
 \mathbf{g}_{12} &= \frac{\partial \delta \mathbf{b}_{b_{k+1}}}{\partial \delta \mathbf{n}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{q}_{b_l b_k} \otimes \left[ \frac{1}{2} \left( \boldsymbol{\omega} - \frac{1}{2} \delta \mathbf{n}_k^g \right) \delta t \right] (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{n}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{R}_{b_l b_k} \exp \left( \left[ \left( \boldsymbol{\omega} - \frac{1}{2} \delta \mathbf{n}_k^g \right) \delta t \right]_{\times} \right) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{n}_k^g} \\
 &= \frac{1}{4} \frac{\partial \mathbf{R}_{b_l b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) \exp \left( \left[ -J_r(\boldsymbol{\omega} \delta t) \frac{1}{2} \delta \mathbf{n}_k^g \delta t \right]_{\times} \right) (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2}{\partial \delta \mathbf{n}_k^g} \\
 &= -\frac{1}{4} \frac{\partial \mathbf{R}_{b_l b_{k+1}} \left( \left[ (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \delta t^2 \right]_{\times} \right) \left( -J_r(\boldsymbol{\omega} \delta t) \frac{1}{2} \delta \mathbf{n}_k^g \delta t \right)}{\partial \delta \mathbf{n}_k^g} \\
 &= -\frac{1}{4} \left( \mathbf{R}_{b_l b_{k+1}} \left[ (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \right]_{\times} \delta t^2 \right) \left( -J_r(\boldsymbol{\omega} \delta t) \frac{1}{2} \delta t \right) \\
 &= -\frac{1}{4} \left( \mathbf{R}_{b_l b_{k+1}} \left[ (\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a) \right]_{\times} \delta t^2 \right) \left( -\frac{1}{2} \delta t \right)
 \end{aligned}$$

根据  $\boldsymbol{\omega} = \frac{1}{2}((\boldsymbol{\omega}^{b_k} + \mathbf{n}_k^g - \mathbf{b}_k^g) + (\boldsymbol{\omega}^{b_{k+1}} + \mathbf{n}_{k+1}^g - \mathbf{b}_k^g))$ ，经过  $\delta \mathbf{n}_k^g$  抖动后变为  $\boldsymbol{\omega} + \frac{1}{2} \delta \mathbf{n}_k^g$ ，与 2.1 中  $\boldsymbol{\omega} - \delta \mathbf{b}_k^g$  相比  $g_{12} = \frac{\partial \delta \alpha_{k+1}}{\partial \delta \mathbf{n}_k^g}$  推导仅仅是  $-\delta \mathbf{b}_k^g$  和  $\frac{1}{2} \delta \mathbf{n}_k^g$  的区别，所以把  $-\delta \mathbf{b}_k^g$  替换为  $\frac{1}{2} \delta \mathbf{n}_k^g$  就可以得到结果：

$$\begin{aligned}
 g_{12} &= \frac{\partial \delta \alpha_{k+1}}{\partial \delta \mathbf{n}_k^g} \\
 &= \frac{-\partial \frac{1}{4} (R_{b_l b_k} \exp([\boldsymbol{\omega} \delta t]_{\times}) [\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a]_{\times} (J_r(\boldsymbol{\omega} \delta t) \frac{1}{2} \delta \mathbf{n}_k^g \delta t) \delta t^2}{\partial \delta \mathbf{n}_k^g} \\
 &= -\frac{1}{4} R_{b_l b_{k+1}} [\mathbf{a}^{b_{k+1}} - \mathbf{b}_k^a]_{\times} \delta t^2 \left( \frac{1}{2} \delta t \right)
 \end{aligned}$$

两道题完全同理

# 第三题

证明:

阻尼因子  $\mu$  大小是相对于  $J^T J$  的元素而言的。半正定的信息矩阵  $J^T J$  特征值  $\{\lambda_j\}$  和对应的特征向量为  $\{v_j\}$ 。对  $J^T J$  做特征值分解分解后有:  $J^T J = V \Lambda V^T$  可得:

$$\Delta x_{lm} = - \sum_{j=1}^n \frac{v_j^T F'^T}{\lambda_j + \mu} v_j \quad (9)$$

$$\begin{aligned} (V \Lambda V^T + \mu I) \Delta x_{lm} &= -F'^T \\ \therefore (V \Lambda V^T + V \cdot \mu I \cdot V^T) \cdot \Delta x_{lm} &= -F'^T \\ V (\Lambda + \mu I) V^T \cdot \Delta x_{lm} &= -F'^T \\ \therefore \Delta x_{lm} &= -(V (\Lambda + \mu I) V^T)^{-1} F'^T \\ &= -V (\Lambda + \mu I)^{-1} \cdot V^T \cdot F'^T \\ &= -(v_1 \cdots v_n) \cdot \begin{pmatrix} \frac{1}{\lambda_1 + \mu} & & \\ & \ddots & \\ & & \frac{1}{\lambda_n + \mu} \end{pmatrix} \begin{pmatrix} v_1^T F'^T \\ \vdots \\ v_n^T F'^T \end{pmatrix} \\ &= -(v_1 \cdots v_n) \begin{pmatrix} \frac{v_1^T F'^T}{\lambda_1 + \mu} \\ \vdots \\ \frac{v_n^T F'^T}{\lambda_n + \mu} \end{pmatrix} \\ &= - \sum_{j=1}^n \frac{v_j^T F'^T}{\lambda_j + \mu} \cdot v_j \end{aligned}$$

维数为  $1 \times 1$ , 标量

证毕!

感谢各位聆听 !

Thanks for Listening

